Лабораторная работа 3. Транспонирование матрицы и исследование локальности памяти. Вариант H

Реализованы пять вариантов транспонирования квадратной матрицы (последовательные и OpenMP) и два дополнительных варианта in-place. Для H использованы элементы float и N_v = 5500. Один прогрев, 5 измерений (медиана), поэлементная проверка: во всех запусках check=OK.

Система: AMD Ryzen 7 5700U, 8 ядер / 16 потоков; кеш L1 — 512 КиБ, L2 — 4 МиБ, L3 — 8 МиБ (суммарно); GCC 16.1.0 (MSYS2), -O2.

Эксперимент 1. Порядок обхода, 1 поток

N	Время rows, с	Время cols, с	BW rows, ГБ/с	BW cols, ГБ/с
256	0,000397	0,000144	1,322	3,634
512	0,003066	0,001289	0,684	1,626
1024	0,018789	0,014158	0,446	0,593
2048	0,083500	0,052500	0,402	0,639
5500	0,452000	0,458000	0,535	0,528

Эксперимент 2. Размер блока, 1 поток, N = 5500

Размер блока b	Время, с	BW, ГБ/с
4	0,135	1,793
8	0,127	1,906
16	0,102	2,373
32	0,074	3,270
64	0,059	4,102
128	0,056	4,321

Эксперимент 3. Количество потоков, N = 5500, b* = 128

Потоки	Время rows_omp, с	S rows_omp	Время blocked_omp, с	S blocked_omp
1	0,459	0,985	0,059	7,661
2	0,232	1,948	0,045	10,044
4	0,114	3,965	0,033	13,697
8	0,083	5,446	0,028	16,143
16	0,069	6,551	0,025	18,080

Эксперимент 4. False sharing, N = 5500, 8 потоков

Стратегия	Время, с	BW, ГБ/с
schedule(static)	0,083	2,916
schedule(static, 1)	0,093	2,602
schedule(static, 8)	0,067	3,612

Дополнительное задание (+1 балл). Транспонирование на месте, N = 5500

Версия	Потоки	Время, с
inplace	1	0,182
inplace_omp	8	0,077
blocked_omp (для сравнения)	8	0,028

Вывод

При N=256–2048 обход cols быстрее rows, поскольку последовательная запись в B улучшает локальность; при N=5500 время обеих версий почти одинаково. Лучшее блочное транспонирование при одном потоке получено с b*=128 (0,056 с). Два блока по 128×128 элементов float занимают около 128 КиБ, что больше кеша L1 одного ядра, но помещается в L2 (512 КиБ на ядро). При 16 потоках rows_omp достиг ускорения 6,55, а blocked_omp — 18,08 относительно последовательной rows; второе значение включает выигрыш от блокирования. Ускорение транспонирования ограничено пропускной способностью памяти сильнее, чем вычисление интеграла из ЛР2, поэтому добавление потоков постепенно даёт меньшую отдачу. При schedule(static, 1) время выросло до 0,093 с против 0,083 с у static из-за более частого совместного использования кеш-линий B разными потоками (false sharing). Schedule(static, 8) показал 0,067 с, а дополнительная inplace_omp — 0,077 с: она экономит память под B, но уступает blocked_omp (0,028 с).